

Analyse automatique d'avis clients

Aspect-Based Sentiment Analysis appliquée aux avis Amazon, catégorie Baby Products

Advanced Practical Machine Learning, Professeur Souheil Hanoune, aivancity School of AI and Data

Rapport de projet

1. Introduction et problématique

Les entreprises reçoivent chaque jour un volume important d'avis clients qu'il est difficile d'analyser manuellement. Une simple note globale ne permet pas d'identifier précisément les points forts et les axes d'amélioration d'un produit ou d'un service. Un même avis peut être très positif sur le prix et très négatif sur la sécurité, sans que la note moyenne ne le révèle. Ce projet a pour objectif de développer un système de traitement automatique du langage capable d'extraire, pour chaque avis, les aspects concrets évoqués (qualité du produit, prix, sécurité, facilité d'usage, etc.) et le sentiment associé à chacun d'eux. Cette tâche est connue sous le nom d'Aspect-Based Sentiment Analysis, ou ABSA.

Le domaine retenu est celui des produits pour bébés, à partir du corpus public Amazon Reviews 2023, catégorie Baby Products. Ce choix correspond à un cas d'usage directement transposable à des enseignes de puériculture, des plateformes e-commerce ou des services qualité, qui ont besoin de comprendre finement les retours clients au-delà d'une note globale.

2. Données et méthodologie de labellisation

Le jeu de données brut est constitué d'avis clients réels (texte, note, statut d'achat vérifié) issus d'Amazon Reviews 2023. Aucune annotation manuelle d'aspect ni de sentiment n'étant disponible, une étape de pseudo labellisation par weak supervision a été mise en place afin de transformer ces avis bruts en un jeu de données exploitable pour l'entraînement supervisé des modèles.

2.1 Pipeline de pseudo labellisation

Chaque avis est d'abord segmenté en phrases avec spaCy (module preprocess.py). Chaque phrase suit ensuite deux étapes de classification automatique, assurées par des modèles Hugging Face pré-entraînés.

- **Détection d'aspect.** Un modèle zero shot NLI (DistilBERT MNLI, ou BART large MNLI pour une meilleure qualité) évalue la phrase contre dix catégories d'aspects candidates : qualité du produit, prix, design, taille, confort, durabilité, sécurité, facilité d'usage, livraison, service client. Ces catégories sont formulées comme des hypothèses NLI. Le score obtenu est renforcé par des règles lexicales fondées sur des expressions régulières, qui rattrapent les aspects évidents ratés par le modèle zero shot (module aspects.py).
- **Détection de sentiment.** Un classifieur DistilBERT fine tune sur SST-2 attribue une polarité binaire, positive ou négative, à chaque phrase (module classifiers.py).

L'orchestration complète du pipeline (pipeline.py, build_aspect_labels.py) traite les avis par lots, avec reprise automatique en cas d'interruption, ce qui est important compte tenu du volume de données et du temps de calcul nécessaire sur CPU.

2.2 Préparation et répartition des données

Le nettoyage (prep_data.py) decode les entités HTML résiduelles, retire les balises et les URLs, normalise la ponctuation typographique et deduplique les lignes identiques. Le découpage en ensembles d'entraînement, de validation et de test est réalisé par groupe sur l'identifiant de l'avis (review_idx), avec un GroupShuffleSplit dans les proportions 80, 10 et 10 pour cent. Cette méthode garantit qu'un même avis, pouvant contenir plusieurs phrases, ne se retrouve jamais réparti entre plusieurs ensembles, ce qui éviterait une fuite de données. Un vocabulaire est ensuite construit exclusivement sur l'ensemble d'entraînement, avec une fréquence minimale de deux occurrences et une taille maximale de 20000 tokens, pour la tokenisation du

modele Bi-LSTM. Le modele BERT utilise directement son propre tokenizer WordPiece sur le texte nettoye, sans passer par ce vocabulaire.

Le jeu de test final comprend 5569 exemples, sous forme de paires phrase et aspect, repartis en 3580 exemples positifs et 1989 exemples negatifs. Cette distribution desequilibree a un impact sur les resultats, discute en section 5.

3. Formulation de la tache et architectures des modeles

Les deux modeles developpes resolvent la meme tache formelle : etant donnee une paire composee d'un aspect et d'une phrase, predire un sentiment binaire, positif ou negatif. L'aspect fait partie integrante de l'entree du modele. Sans lui, il serait impossible de distinguer, dans la phrase *the price is great but the safety strap is flimsy*, que l'aspect *price* est positif alors que l'aspect *safety* est negatif dans la meme phrase. Deux architectures ont ete entraenees et comparees : un reseau recurrent entraene entierement depuis zero, et un modele de type transformeur pre entraene, adapte par fine tuning.

3.1 Baseline Bi-LSTM (train_baseline.py)

Le modele de reference comporte les couches suivantes, dans l'ordre du calcul.

- Une couche d'embedding de mots, de dimension 128, initialisee aleatoirement et apprise pendant l'entrainement, avec un indice de padding fixe a zero. La taille de cette matrice depend du vocabulaire construit sur l'ensemble d'entrainement, plafonne a 20000 tokens (soit au maximum environ 2,56 millions de parametres pour cette seule couche).
- Une couche d'embedding d'aspect, de dimension 32, avec un vecteur distinct pour chacune des dix categories d'aspects (320 parametres au total).
- Un reseau recurrent LSTM bidirectionnel a une seule couche, avec 128 unites cachees par direction. La sequence de mots est parcourue simultanement de gauche a droite et de droite a gauche. Le dernier etat cache de chaque direction est concatene, ce qui produit une representation de phrase de dimension 256. Ce bloc recurrent compte environ 264000 parametres entraenes.
- Une concatenation entre la representation de phrase (256) et l'embedding de l'aspect cible (32), formant un vecteur de dimension 288.
- Une tete de classification a deux couches lineaires : une premiere couche cachee de 288 vers 128 neurones, suivie d'une activation ReLU et d'un dropout a 0,3, puis une seconde couche lineaire de 128 vers 2 neurones, correspondant aux deux classes de sortie. Cette tete represente environ 37250 parametres.

Hors la matrice d'embedding de mots, dont la taille varie avec le vocabulaire, le reste du reseau represente environ 302000 parametres entraenes. L'entrainement utilise l'optimiseur Adam avec un taux d'apprentissage de $1e-3$, des lots de 32 exemples, jusqu'a 30 epoques, avec un arret anticipe si le F1 macro de validation ne progresse plus pendant 5 epoques consecutives.

3.2 BERT fine tune (train_bert.py)

Le second modele repose sur bert-base-uncased, un transformeur pre entraene compose de 12 couches d'encodeur empilees. Chaque couche applique un mecanisme d'auto-attention multi-tete, avec 12 tetes d'attention, sur une representation cachee de dimension 768, suivi d'un reseau de neurones a propagation avant de dimension interne 3072 (soit quatre fois la taille cachee), avant de revenir a la dimension 768 en sortie de couche. L'ensemble du modele pre entraene compte environ 110 millions de parametres, tous ajustes pendant le fine tuning, sans gel de couche.

La phrase et l'aspect sont codes conjointement, au format dit BERT-SPC : la sequence d'entree est construite comme le jeton special CLS, suivi des tokens de l'aspect, du jeton separateur SEP, des tokens de la phrase, puis d'un second jeton SEP. Cette mise en forme permet au mecanisme d'attention de mettre directement en relation les mots de la phrase avec l'aspect cible des la premiere couche, ce qui constitue une


différence structurelle majeure avec le Bi-LSTM, qui encode la phrase et l'aspect séparément avant de les combiner tardivement. La longueur maximale de séquence est fixée à 96 tokens.

La tête de classification ajoutée au dessus du transformeur reprend l'architecture standard de bert-base pour la classification de séquences : la représentation du jeton CLS en sortie de la douzième couche est d'abord passée dans une couche linéaire de pooling (768 vers 768) suivie d'une activation tangente hyperbolique, puis dans un dropout, avant une dernière couche linéaire de 768 vers 2 neurones produisant les scores des deux classes. L'entraînement utilise l'optimiseur AdamW avec un taux d'apprentissage de $2e-5$, une décroissance de poids de 0,01, un warmup linéaire sur 10 pour cent des pas, des lots de 16 exemples, jusqu'à 4 époques, avec un arrêt anticipé après 2 époques sans progression du F1 macro de validation.

4. Resultats quantitatifs

Les deux modèles ont été évalués sur le même ensemble de test, 5569 exemples, avec le meilleur point de sauvegarde de chacun sélectionné selon le F1 macro de validation. Le F1 macro est retenu comme métrique de référence plutôt que l'accuracy seule, car il donne un poids égal aux deux classes malgré leur déséquilibre, 64 pour cent d'exemples positifs contre 36 pour cent de négatifs.

Métrique	Baseline Bi-LSTM	BERT fine tune	Gain BERT
Accuracy	81,79 %	92,93 %	+11,13 pts
Precision macro	80,13 %	92,66 %	+12,53 pts
Recall macro	80,46 %	91,84 %	+11,37 pts
F1-score macro	80,29 %	92,22 %	+11,94 pts



Classe	Precision Bi-LSTM	Recall Bi-LSTM	F1 Bi-LSTM	Precision BERT	Recall BERT	F1 BERT
negative (n=1989)	0,74	0,76	0,75	0,92	0,88	0,90
positive (n=3580)	0,86	0,85	0,86	0,94	0,96	0,95

BERT surpasse la baseline sur toutes les métriques, avec un gain particulièrement marqué sur la classe négative, minoritaire, dont le F1 passe de 0,75 à 0,90. Ce résultat est cohérent avec l'apport attendu du pré-entraînement à grande échelle pour mieux généraliser sur une classe sous-représentée. Sur les 5569 exemples de test, les deux modèles sont en désaccord sur 918 exemples, soit 16,5 pour cent. BERT corrige une erreur de la baseline dans 769 cas, soit 13,8 pour cent du total, mais introduit une nouvelle erreur là où la baseline avait

raison dans 149 cas, soit 2,7 pour cent. Ces deux categories de desaccord, ainsi que les cas ou les deux modeles se trompent, 245 cas soit 4,4 pour cent, sont analyses qualitativement en section 5.

5. Analyse d'erreurs qualitative

Au dela des metriques agregees, l'examen d'exemples individuels tires du fichier `categorized_errors.csv` permet de comprendre ou et pourquoi chaque modele se trompe, et de questionner la fiabilite des pseudo labels issus du pipeline de weak supervision decrit en section 2.1. Trois categories sont examinees : les cas ou BERT corrige une erreur du Bi-LSTM, les cas ou BERT introduit une erreur inedite, et les cas ou les deux modeles echouent.

5.1 BERT corrige la baseline

Phrase	Aspect	Label	Bi-LSTM	BERT
these locks really helped in securing them, they did not open even when kid tried forcedly, 1 star less due to difficulty in removal	qualite du produit	positive	negative	positive
This is also easy to put on the baby, it zips right up or down, with the two way zipper.	facilite d'usage	positive	negative	positive
Nice but to small for my use.	taille et ajustement	positive	negative	positive

Le premier exemple est une phrase longue et globalement positive qui contient pourtant une negation (did not open) et se termine sur une note negative mineure (1 star less). La baseline semble s'etre lailsee dominer par ce signal de fin de phrase et par la negation, alors que BERT integre correctement l'ensemble du contexte pour degager le sentiment global positif dominant. Le deuxieme exemple est plus surprenant, car aucune negation n'est presente et la baseline echoue tout de meme. Ceci suggere que ses embeddings, appris depuis zero sur un vocabulaire limite, representent mal certaines tournures que BERT, pre entraine sur un corpus massif, traite nativement. Le troisieme exemple illustre une limite du pipeline de pseudo labellisation lui meme. Le texte est objectivement critique sur la taille, et la prediction negative de la baseline correspond a une lecture humaine plausible, tandis que l'accord de BERT avec le label positif ne prouve pas necessairement une meilleure comprehension du sens, mais peut etre seulement une meilleure capacite a reproduire les biais du classifieur de sentiment utilise pour generer les labels.

5.2 BERT introduit une nouvelle erreur

Phrase	Aspect	Label	Bi-LSTM	BERT
When she comes to visit, she picks this toy out of the pile of toys to play with first every time.	qualite du produit	negative	negative	positive
However, with these locks he has not been able to get around it, so we are beyond impressed!	design et apparence	negative	negative	positive
It was a little expensive and I hope it holds for a few years.	qualite du produit	positive	positive	negative

Les deux premiers cas sont, comme en section 5.1, des candidats serieux a l'erreur de pseudo label plutot qu'a l'erreur de modele. La premiere phrase decrit un jouet prefere d'un enfant, un signal tres positif, mais porte un label negative. La seconde combine une double negation, has not been able to get around it, qui signifie en realite que le dispositif de securite fonctionne bien, renforcee par beyond impressed, un sentiment manifestement positif malgre un label negative. Dans les deux cas, BERT predit positive, une lecture plus proche du sens reel du texte que le label utilise pour l'evaluer, tandis que la baseline a raison vis a vis du label sans que cela ne prouve une meilleure comprehension. Le troisieme exemple est en revanche une veritable erreur de BERT. Le langage y est hesitant plutot que negatif, a little expensive, I hope. BERT semble sur ponderer le mot expensive et manque le ton globalement positif et prudent de la phrase, un piege classique du langage nuance que meme un modele pre entraine ne resout pas toujours.

5.3 Les deux modeles se trompent

Phrase	Aspect	Label	Bi-LSTM	BERT
This is a great sleeper sack!	confort et texture	negative	positive	positive
VIDEOID, This is a take anywhere light stroller.	securite	positive	negative	negative
It kept him safe and he could crawl out when ready.	securite	negative	positive	positive

Le premier exemple est le cas le plus net de bruit de labellisation rencontre dans cette analyse. La phrase est sans ambiguïté enthousiaste, great, et les deux modeles la lisent, a raison, comme positive. Leur erreur commune est en fait un desaccord justifie avec un label probablement errone. Le deuxieme exemple revele une limite de pretraitement. Un jeton residuel de type identifiant de video, artefact de balisage Amazon non nettoye en amont, pollue une phrase par ailleurs neutre et sans signal de sentiment clair, ce qui perturbe les deux modeles de facon similaire. C'est une piste d'amelioration concrete du pipeline de nettoyage, module preprocess.py, fonction clean_text. Le troisieme exemple est un desaccord plus legitime. Kept him safe est positif, mais could crawl out when ready peut aussi bien decrir une fonctionnalite voulue qu'une faille de securite selon le contexte plus large de l'avis, non disponible au niveau de la phrase isolee. Il s'agit d'un cas d'ambiguite reelle plutot que d'une erreur de labellisation.

6. Discussion critique et limites

L'analyse qualitative de la section 5 met en evidence une limite methodologique centrale du projet, plus importante que le simple ecart de performance entre les deux architectures. Une part significative des desaccords entre les modeles, et une partie des cas ou les deux se trompent, semble provenir non pas d'une faiblesse de modelisation, mais du bruit inherent au pipeline de pseudo labellisation par weak supervision. Les labels d'entrainement et de test ne sont pas des annotations humaines. Ils proviennent de modeles tiers pre entraines, NLI zero shot et sentiment SST-2, eux memes faillibles et appliques phrase par phrase, hors du contexte complet de l'avis. Ce choix etait necessaire compte tenu du volume de donnees et de l'absence de budget d'annotation manuelle, mais il implique qu'une partie de l'ecart mesure entre BERT et le Bi-LSTM reflète en realite la capacite de chaque modele a reproduire les biais du pipeline de labellisation, plutot qu'une comprehension semantique plus fine. Une evaluation sur un petit echantillon annote manuellement constituerait l'amelioration methodologique la plus pertinente pour objectiver la performance reelle des deux modeles.

Deux limites secondaires, plus techniques, ont egalement ete identifiees. La segmentation de phrases par spaCy peut tronquer des phrases complexes au niveau de points de suspension, produisant des fragments grammaticalement incomplets et semantiquement ambigus. Le nettoyage de texte ne retire pas systematiquement certains artefacts de balisage Amazon, comme les jetons d'identifiant de video, qui polluent le signal textuel pour les deux modeles de facon comparable. Enfin, l'analyse confirme que le taux d'erreur de BERT est plus eleve sur les phrases contenant un marqueur de negation ou de contraste, 9,77 pour cent contre 6,19 pour cent sans negation. Ce motif est documente dans la litterature ABSA : la negation et les constructions concessives, however, but, double negation, restent un defi meme pour des modeles pre entraines a grande echelle.

7. Conclusion

Ce projet demontre la faisabilite d'un systeme d'analyse d'avis clients par aspect entierement construit a partir de donnees reelles non annotees, en combinant un pipeline de pseudo labellisation par weak supervision avec deux architectures PyTorch entrainees et comparees de bout en bout, un Bi-LSTM de reference et un BERT fine tune. Le gain de performance de BERT, 11,9 points de F1 macro, confirme l'interet du transfer learning pour cette tache, en particulier sur la classe negative minoritaire. L'analyse d'erreurs qualitative, au dela de confirmer ce resultat quantitatif, a surtout revele une limite structurelle plus importante que prevu, la fiabilite

des pseudo labels eux memes, qui constitue la principale piste d'amelioration pour une iteration future du projet, avant meme l'ajustement des architectures. La demonstration Streamlit permet de rendre ce systeme accessible a un utilisateur final, enseigne de puericulture, plateforme e-commerce ou service qualite, qui peut soumettre un avis ou un corpus d'avis et visualiser immediatement les aspects detectes et leur polarite.

References

- Devlin, J., Chang, M. W., Lee, K., Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
- Pontiki, M., Galanis, D., Papageorgiou, H., Androutsopoulos, I., Manandhar, S., Mohammad, A. S., et al. (2016). SemEval-2016 Task 5: Aspect Based Sentiment Analysis.
- Hochreiter, S., Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.
- Lewis, M., et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension (modele bart-large-mnli, zero shot NLI).